

Rapport final

Projet Machine Learning — Global Superstore

Équipe	Code Master
Dataset	Global_Superstore2.csv
Méthodologie	CRISP-DM
Année	2026

Rapport final – Projet Machine Learning Global Superstore

Introduction

Ce rapport présente le travail réalisé dans le cadre du projet Machine Learning appliqué au dataset **Global Superstore**. Le projet vise à exploiter des données transactionnelles d'un supermarché mondial afin d'améliorer la prise de décision commerciale à travers plusieurs objectifs Data Science.

Le travail a été organisé selon la méthodologie **CRISP-DM**, qui structure un projet data en plusieurs phases : compréhension métier, compréhension des données, préparation des données, modélisation, évaluation et déploiement.

Le dataset utilisé est :

- **Nom du fichier** : Global_Superstore2.csv
- **Nombre de lignes initiales** : 51 290
- **Nombre de colonnes initiales** : 24
- **Domaine** : ventes, clients, produits, régions, profits, remises et livraison

Le projet est divisé en **6 DSO** :

DSO	Objectif	Modèles principaux	Responsable
DSO1	Segmentation clients	K-Means, DBSCAN	Syrine Jedidi
DSO2	Prédiction des ventes	Decision Tree, Random Forest	Alaa Tahri
DSO3	Optimisation des ventes	AdaBoost, XGBoost	Aziz Msekni
DSO4	Recommandation produits	SVD	Nourane Lammouchi
DSO5	Classification des commandes	KNN, SVM	Wala Rezgui
DSO6	Détection d'anomalies et régression	Isolation Forest, Naive Bayes, régressions	Ibtihel Mechergui

L'objectif final est de construire un notebook complet et une application web permettant de présenter et tester les résultats des différents modèles.

Compréhension métier

Le contexte métier concerne un supermarché mondial qui souhaite exploiter ses données transactionnelles pour améliorer ses performances commerciales.

Les données disponibles permettent d'analyser :

- les ventes par produit, région, catégorie et segment client ;
- la rentabilité des commandes ;
- les remises appliquées ;
- les coûts et délais de livraison ;
- les comportements d'achat des clients ;
- les commandes atypiques ou risquées.

La problématique principale est :

Comment exploiter les données transactionnelles du dataset Global Superstore pour optimiser les performances commerciales d'un supermarché mondial grâce au Machine Learning ?

Cette problématique est décomposée en **BOs** (*Business Objectives*) et **DSOs** (*Data Science Objectives*). Les BOs expriment les besoins métier, tandis que les DSOs traduisent ces besoins en objectifs techniques mesurables.

BO – Business Objective	DSO – Data Science Objective	Modèles / méthodes	Résultat attendu
Mieux comprendre les clients	DSO1 – Segmenter les clients	K-Means, DBSCAN	Identifier des profils clients exploitables
Anticiper les ventes	DSO2 – Prédire les ventes	Decision Tree, Random Forest	Estimer Sa l es avec une bonne précision
Améliorer la performance prédictive	DSO3 – Optimiser la prédiction des ventes	AdaBoost, XGBoost	Sélectionner le meilleur modèle de régression
Améliorer le cross-selling	DSO4 – Recommander des produits	SVD	Proposer des produits pertinents

BO – Business Objective	DSO – Data Science Objective	Modèles / méthodes	Résultat attendu
Prioriser les commandes	DSO5 – Classifier les commandes	KNN, SVM	Distinguer commandes faibles et fortes
Surveiller les comportements atypiques	DSO6 – Détecter anomalies et délais	Isolation Forest, Naive Bayes, régressions	Identifier anomalies et analyser Delivery_Days

Une autre lecture synthétique des besoins est la suivante :

Besoin métier	Objectif Data Science
Comprendre les profils clients	Segmenter les clients selon leurs comportements d'achat
Anticiper les ventes	Prédire le montant des ventes d'une commande
Améliorer la précision des prédictions	Tester des modèles avancés comme XGBoost
Améliorer le cross-selling	Recommander des produits pertinents
Identifier les commandes importantes	Classifier les commandes faibles ou fortes
Surveiller les comportements atypiques	Détecter les anomalies et analyser les délais

Ainsi, chaque DSO répond à un besoin métier spécifique tout en utilisant le même dataset.

Compréhension des données

Le dataset **Global Superstore** contient des informations relatives aux commandes passées dans différentes régions du monde.

Les principales colonnes sont :

Colonne	Description
Order Date	Date de commande
Ship Date	Date d'expédition
Ship Mode	Mode d'expédition
Customer ID	Identifiant client
Customer Name	Nom du client
Segment	Segment client
City, State, Country	Localisation
Market, Region	Marché et région
Category, Sub-Category	Catégorie et sous-catégorie produit
Product Name	Nom du produit
Sales	Montant des ventes
Quantity	Quantité commandée
Discount	Remise appliquée
Profit	Profit réalisé
Shipping Cost	Coût de livraison
Order Priority	Priorité de la commande

L'analyse exploratoire a permis d'identifier :

- la taille du dataset : **51 290 lignes** ;
- la présence de colonnes numériques et catégorielles ;
- une colonne Postal Code fortement incomplète ;
- des variables importantes pour la modélisation : Sales, Profit, Quantity, Discount, Shipping Cost ;
- des variables catégorielles utiles : Region, Category, Sub-Category, Segment, Ship Mode.

Des visualisations ont été réalisées :

- histogrammes des variables numériques ;
- boxplots pour détecter les outliers ;
- countplots pour les variables catégorielles ;
- matrice de corrélation ;

- analyse par segment, région et catégorie ;
- ACP pour comprendre les relations entre variables quantitatives.

L'analyse a montré que les ventes et profits sont influencés par plusieurs facteurs : quantité, coût de livraison, remise, catégorie produit, région et comportement client.

Préparation des données

La phase de préparation a permis de nettoyer et transformer les données afin de les rendre exploitables pour les modèles.

Les principales étapes réalisées sont :

1. Conversion des dates :

- Order Date et Ship Date ont été converties en format date.
- Une nouvelle variable Delivery_Days a été créée :

```
Delivery_Days = Ship Date - Order Date
```

2. Suppression des colonnes peu utiles ou non adaptées :

- Row ID
- Order ID
- Customer Name
- Product ID
- Postal Code

3. Filtrage métier :

- conservation des quantités positives ;
- conservation des ventes positives ;
- contrôle des remises ;
- contrôle du coût de livraison par rapport aux ventes.

4. Gestion des outliers :

Les outliers ont été traités avec la méthode IQR sur les colonnes :

- Sales
- Profit
- Discount
- Shipping Cost

5. Création de variables dérivées :

- Delivery_Days
- Profit_Margin
- Discount_Rate
- Order_Year
- Order_Month
- Order_Day
- Order_Week

6. Encodage des variables catégorielles :

Les variables catégorielles ont été transformées afin d'être utilisables par les modèles :

- encodage des colonnes texte ;
- création de variables binaires pour certaines catégories ;

- standardisation ou normalisation selon les modèles.

Après préparation et suppression des outliers, le nombre de lignes utilisées pour la modélisation est :

14 618 observations

Modélisation

La phase de modélisation regroupe les 6 DSO du projet.

DSO1 – Segmentation clients

Objectif : regrouper les clients en segments homogènes selon leur comportement d'achat.

Les données ont été agrégées par client avec les variables suivantes :

- Total_Sales
- Avg_Order_Value
- Order_Count
- Total_Profit
- Avg_Profit_Margin
- Avg_Discount_Rate
- Avg_Delivery_Days

Modèles utilisés :

- **K-Means**, avec $k = 4$
- **DBSCAN**

Résultats :

Modèle	Métrique	Résultat
K-Means	Silhouette	0.2770
K-Means	Davies-Bouldin	1.3209
DBSCAN	Silhouette	0.3404
DBSCAN	Davies-Bouldin	2.7373
DBSCAN	Bruit détecté	10.2 %

Interprétation :

- DBSCAN donne une meilleure silhouette.
- K-Means donne un meilleur score Davies-Bouldin, ce qui indique des clusters plus compacts et mieux séparés selon cette métrique.
- DBSCAN détecte automatiquement du bruit, mais il isole **10.2 %** des clients comme points bruités, ce qui complique l'interprétation métier et l'utilisation opérationnelle.
- K-Means produit exactement **4 segments**, ce qui correspond au besoin métier : créer des groupes lisibles, stables et activables par les équipes marketing.
- K-Means a donc été retenu pour l'application web, non pas parce qu'il domine toutes les métriques, mais parce qu'il offre le meilleur compromis entre performance, stabilité et interprétabilité métier.

DSO2 – Prédiction des ventes

Objectif : prédire le montant des ventes Sales.

Modèles utilisés :

- **Decision Tree Regressor**
- **Random Forest Regressor**

Résultats :

Modèle	MAE	RMSE	R ²
Decision Tree	29.1992	54.9796	0.4856
Random Forest	20.3980	37.6652	0.7586

Interprétation :

Random Forest donne de meilleurs résultats que l'arbre de décision simple. Il réduit l'overfitting et améliore la précision des prédictions.

DSO3 – Optimisation des ventes

Objectif : améliorer la prédiction des ventes avec des modèles de boosting.

Modèles utilisés :

- **AdaBoost Regressor**
- **XGBoost Regressor**

Résultats :

Modèle	MAE	RMSE	R ²
AdaBoost	31.1266	48.4058	0.6013
XGBoost	18.4326	34.1136	0.8020

Interprétation :

XGBoost est le meilleur modèle de régression du projet. Il obtient le meilleur R² et le RMSE le plus faible pour la prédiction des ventes.

Le choix de XGBoost est donc défendable avec les deux métriques : **le RMSE diminue** par rapport à AdaBoost, ce qui signifie une erreur moyenne plus faible en valeur de ventes, et **le R² augmente**, ce qui signifie que le modèle explique mieux la variance de Sales. Dans la synthèse globale, le RMSE est mis en avant car il est directement interprétable comme une erreur de prédiction sur la cible métier.

DSO4 – Recommandation produits

Objectif : recommander des produits à partir de la matrice client-produit.

Modèle utilisé :

- **SVD**, via TruncatedSVD

Le système construit une matrice client-produit basée sur les interactions d'achat, puis utilise une réduction de dimension pour estimer des recommandations.

Résultats :

Indicateur	Résultat
RMSE SVD	5.32
Precision@5	0.0011

Interprétation :

La Precision@5 est faible, ce qui montre que les recommandations peuvent être améliorées avec davantage de données ou de signaux supplémentaires, comme les avis clients, les historiques de navigation ou la saisonnalité.

Pour ce DSO, aucune alternative de recommandation n'a été testée dans le notebook. **SVD est donc retenu comme baseline**, c'est-à-dire comme première approche de référence pour construire une matrice client-produit et générer des recommandations.

DSO5 – Classification des commandes

Objectif : classer les commandes en classes faibles ou fortes selon le montant des ventes.

Modèles utilisés :

- **KNN**
- **SVM**

Résultats :

Modèle	Accuracy
KNN	0.8157
SVM	0.9056

Interprétation :

SVM donne la meilleure performance avec une accuracy de **0.9056**. Il est donc plus adapté que KNN pour séparer les commandes faibles et fortes.

DSO6 – Détection d'anomalies et régression

Objectif : détecter les commandes atypiques et analyser les délais de livraison.

Modèles utilisés :

- Isolation Forest
- Gaussian Naive Bayes
- Régression linéaire
- Régression polynomiale

Résultats :

Approche	Métrique	Résultat
Isolation Forest	Anomalies détectées	293 observations
Isolation Forest	Taux d'anomalies	2.00 %
Naive Bayes	Accuracy	0.62
Naive Bayes	AUC macro	0.6246
Régression linéaire	MAE	1.1587
Régression linéaire	RMSE	1.4765
Régression linéaire	R²	0.2258
Régression polynomiale	MAE	1.1147
Régression polynomiale	RMSE	1.4182
Régression polynomiale	R²	0.2858

Interprétation :

Isolation Forest permet d'identifier une proportion limitée de commandes atypiques. Naive Bayes donne une classification moyenne des niveaux d'anomalie. La régression polynomiale améliore légèrement la prédiction des délais par rapport à la régression linéaire.

Synthèse globale des modèles

DSO	Modèle retenu	Métrique principale	Résultat
DSO1	K-Means	Silhouette	0.2770
DSO2	Random Forest	R²	0.7586
DSO3	XGBoost	RMSE	34.1136
DSO4	SVD	Precision@5	0.0011
DSO5	SVM	Accuracy	0.9056
DSO6	Isolation Forest + Naive Bayes	AUC macro	0.6246

Le meilleur modèle pour la prédiction des ventes est **XGBoost**, avec :

- MAE = 18.4326
- RMSE = 34.1136
- R² = 0.8020

Benchmarking final et justification des choix

Le benchmarking ne se limite pas à choisir le score le plus élevé. Les modèles ont aussi été comparés selon leur interprétabilité, leur stabilité, leur capacité à être intégrés dans l'application web et leur cohérence avec l'objectif métier.

DSO	Modèles comparés	Modèle retenu	Justification
DSO1	K-Means vs DBSCAN	K-Means	Meilleur compromis entre stabilité, interprétabilité et segmentation exploitable en 4 groupes
DSO2	Decision Tree vs Random Forest	Random Forest	Meilleur R² et RMSE plus faible que l'arbre seul
DSO3	AdaBoost vs XGBoost	XGBoost	Meilleur modèle global pour prédire les ventes, R² = 0.8020
DSO4	Aucune alternative testée	SVD baseline	SVD est retenu comme première approche de référence pour la recommandation client-produit
DSO5	KNN vs SVM	SVM	Accuracy nettement supérieure : 0.9056
DSO6	Isolation Forest, Naive Bayes, régressions	Combinaison des approches	Isolation Forest pour détecter les anomalies, Naive Bayes pour les niveaux d'anomalie, régressions pour Delivery_Days

Déploiement

Une application web Flask a été développée afin de présenter les résultats et rendre les modèles plus accessibles.

Statut du déploiement : l'application est actuellement déployée en **local** pour la démonstration technique, via `http://127.0.0.1:5000/`. Elle n'est pas encore publiée sur un serveur cloud accessible publiquement. Pour la maintenance, la démonstration se fait donc depuis la machine locale, avec l'environnement Python et les modèles exportés.

Le déploiement local reste pertinent pour valider :

- le chargement des modèles exportés ;
- l'intégration entre le front-end Flask et la partie IA ;
- la cohérence des formulaires avec le notebook ;
- l'affichage des résultats et métriques pour chaque DSO.

Un déploiement cloud pourra être réalisé ensuite sur Render, Railway, Azure, AWS, PythonAnywhere ou un serveur universitaire.

Le dossier principal de l'application est :

ML/superstore-app

L'application s'appelle **Superstore App**.

Elle contient :

- une page d'accueil ;
- un dashboard global ;
- une page pour chaque DSO ;
- des formulaires de test ;
- des résultats numériques issus du notebook ;
- une interface homogène et adaptée au dataset Global Superstore.

Les pages principales sont :

Page	Description
Accueil	Présentation générale du projet
Dashboard	Synthèse des DSO, modèles et métriques
DSO1	Test de segmentation client
DSO2	Prédiction des ventes avec Random Forest
DSO3	Prédiction des ventes avec XGBoost
DSO4	Recommandation produits
DSO5	Classification faible/forte des commandes
DSO6	Détection de niveau d'anomalie

Lancement local :


```
cd ML\superstore-app
python app.py
```

URL locale :

```
http://127.0.0.1:5000/
```

Les modèles exportés depuis le notebook sont :

Fichier	Utilisation
dso1_kmeans.pkl	Segmentation clients
dso1_scaler_cluster.pkl	Standardisation DSO1
dso2_random_forest.pkl	Prédiction des ventes
dso3_xgboost.pkl	Optimisation des ventes
dso6_isolation_forest.pkl	Détection d'anomalies
dso6_naive_bayes.pkl	Classification des niveaux d'anomalie

L'application permet donc de transformer le notebook en une interface exploitable pour une démonstration métier.

Conclusion et perspectives

Ce projet a permis de construire une solution Machine Learning complète sur le dataset **Global Superstore**.

Les principales réalisations sont :

- exploration et compréhension du dataset ;
- nettoyage et préparation des données ;
- création de variables utiles comme `Delivery_Days`, `Profit_Margin` et `Discount_Rate` ;
- modélisation de 6 objectifs Data Science ;
- comparaison des performances ;
- sélection des modèles les plus efficaces ;
- création d'une application web Flask pour la démonstration.

Les résultats montrent que :

- **K-Means** est exploitable pour segmenter les clients ;
- **Random Forest** donne une bonne prédiction des ventes ;
- **XGBoost** est le meilleur modèle de régression ;
- **SVD** permet de construire une première logique de recommandation ;
- **SVM** est performant pour classifier les commandes ;
- **Isolation Forest** détecte les commandes atypiques ;
- **Naive Bayes** permet une classification des niveaux d'anomalie.

Perspectives d'amélioration

Plusieurs améliorations peuvent être envisagées :

1. Exporter des pipelines complets incluant preprocessing et modèles.
2. Améliorer le système de recommandation avec plus de signaux client.
3. Ajouter une interprétabilité des modèles avec SHAP ou permutation importance.
4. Mettre en place un suivi MLOps : monitoring, réentraînement et versioning.
5. Ajouter une base de données pour historiser les prédictions de l'application.
6. Déployer l'application sur une plateforme cloud.
7. Ajouter une authentification pour un usage professionnel.

En conclusion, le projet montre comment les données transactionnelles de Global Superstore peuvent être exploitées pour répondre à plusieurs problématiques commerciales importantes : segmentation, prévision, recommandation, classification et détection d'anomalies.